

timely hit 与真实 latency saving 的关系

每个点是 workload prompt; saving = No-Prefetch - History 的平均 T_{block}

